

## Resumos MPEI

Probabilidade: Medido do grau de certeza associado a um resultado proveniente de um fenômeno de caixa / observação.

Espaco de Amostragem: conjunto de todos os resultados possíveis de uma experiência.

(S)

eleatório

Discreto

→ se for contável, ou seja, ter um número finito de elementos

Contínuo

Se não for contável

Os seus elementos designam-se por resultados.

• Acontecimento: subconjunto de S

Como determinar a probabilidade?

- Atividade da medição
- Atividade de construção de modelos probabilísticos

Diferentes Abordagens para o cálculo de probabilidades:

- Teoria Clássica (apenas)
- Frequencista
- Teoria Matemática.

### Teoria clássica

$$P(A) = \frac{\text{m. casos favoráveis}}{\text{m. poss}}$$

Perguntas:

- $P(\bar{A}) = 1 - P(A)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

### Nova frequencista

→ medida empírica de probabilidade

$$\bullet f(A) = \frac{\text{n. observações de A}}{\text{n. de experiências}}$$

$$\bullet P(A) = \lim_{N \rightarrow +\infty} \frac{\text{n. observações de A}}{\text{n. de experiências}}$$

$$0 \leq f(A) \leq 1$$

$$\sum_{i=1}^K f(A_i) = 1$$

## Probabilidade condicional:

• Probabilidade de A, sabendo (olhando) B → Joga por:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) \neq 0$$

### Exemplo:

- Uma família tem 2 filhos.
- $P(\text{rapaz}) = 0,5$
- Sabendo que um é rapaz, qual a probabilidade de o outro ser também rapaz?

### Casos favoráveis:

MF  
FM  
FF  
MF

$$P(X) = \frac{P(R \cap R)}{P(R)} = \frac{1/4}{3/4} = \frac{1}{3}$$

pelo menos 1 rapaz

## Regra da. Condicionais / multiplicativa:

$$P(A \cdot B \cdot C) = P(A) \cdot P(B|A) \cdot P(C|A \cdot B)$$

Ex:  $P(\text{"Universidade do Aveiro"}) = P(\text{"Universidade"}) \cdot P(\text{"do" | "Universidade"}) \cdot P(\text{"Aveiro" | "Universidade do"})$

Ex:

- Existem 2 moedas (X e Y) com faces brancas (B) e pretas (P)
- Moeda X → 4 brancos + 3 pretos
- Moeda Y → 5 brancos + 6 pretos

Extraindo uma moeda ao acaso, qual a probabilidade de sair uma branca?

$$P(\text{branca no } X) = P(X) \cdot P(B|X) = \frac{1}{2} \cdot \frac{4}{7} = \frac{4}{14}$$

$$P(\text{branca no } Y) = P(Y) \cdot P(B|Y) = \frac{1}{2} \cdot \frac{5}{11} = \frac{5}{11}$$

$$P(\text{branca}) = \frac{4}{14} + \frac{5}{11} = \frac{7}{14}$$

di da probabilidade total:

$$P(B) = \left\{ \begin{array}{l} P(A_1) \cdot P(B|A_1) \\ + \\ P(A_2) \cdot P(B|A_2) \\ + \\ P(A_3) \cdot P(B|A_3) \end{array} \right\}$$

Condições e inverso / Regra de Bayes:

• se quisirmos  $P(\text{"cima"} | \text{"bola branca"})$

cima  
ejetado


$$P(\text{cima} | \text{ejetado}) = \frac{P(\text{ejetado} | \text{cima}) \times P(\text{cima})}{P(\text{ejetado})}$$

$$P(\text{cima} \times \text{bola branca}) = \frac{P(\text{bola branca} | \text{cima}) \times P(\text{cima})}{P(\text{bola branca})} =$$

$$\frac{\frac{1}{4} \times \frac{1}{2}}{\frac{1}{16}} = \frac{\frac{1}{8}}{\frac{1}{16}} = \frac{1}{2}$$

| Regra do Bayes



$$P(A_i | B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(A_i) \cdot P(B|A_i)}{P(B)}$$
$$= \frac{P(A_i) \cdot P(B|A_i)}{\sum_i P(A_i) \cdot P(B|A_i)}$$



Ejercicio:

$$P(A|B) = ?$$

$$P(B|A) = 0,99$$



$$P(B) = P(B|A) \cdot P(A) + P(B|A-bar) \cdot P(A-bar)$$

$$= 0,1 \cdot 0,95 + 0,99 \cdot 0,05 =$$

$$= 0,095 + 0,0495 =$$

$$P(A|B) = \frac{0,0495}{0,1445} = 0,3406$$

- Vamos à familia de 2 hijos:  
Sabiendo que 1 nació niño, ¿qué es la probabilidad de que el otro sea niño?

$$P(P_R|A_R) = \frac{P(A_R \cap P_R)}{P(A_R)} = \frac{\frac{1}{4}}{\frac{1}{2}} = \frac{1}{2}$$

M	M
M	F
N	F
F	F

Acidentes independentes:

Se, e só se:  $P(A \cap B) = P(A) \cdot P(B)$

→ implica que  $P(A|B) = P(A)$ , mas não é definido

Independência 2 a 2 vs Independência:

$$\Omega_P = \{ HT, HH, TH, TT \}$$

• 2 lances de moedas

• A: moeda 1, cores (Head)

• B: moeda 2 cores

• C: moeda 1 = moeda 2

•  $P(C \cap B) = \frac{1}{4} = \frac{1}{2} \times \frac{1}{2}$

C e B não independentes

$$P(A) = \frac{1}{2} = P(B)$$

$$P(C) = \frac{3}{4} = \frac{1}{2}(q-1) = \frac{1}{2}(1-1) = 0$$

$$\cdot P(C \cap A) = \frac{1}{4} = \underbrace{P(C) \cdot P(A)}_{C \text{ e } A \text{ independentes}}$$

$$\cdot P(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2}$$

A e B não independentes

$$P(C \cap B \cap A) = \frac{1}{4}$$

$$P(C) \cdot P(B) \cdot P(A) = \frac{1}{8} \neq P(C \cap B \cap A)$$

Logo: Independência 2 a 2 não significa independência

Acidentes mutuamente exclusivos

• 2 acidentes mutuamente exclusivos que têm probabilidade ≠ 0 não podem ser independentes

$$\rightarrow P(A \cap B) = 0 \text{ implica } P(A) \cdot P(B) = 0, \text{ o que não é verdade, pois ambas podem ter probabilidade nula}$$

Experiência de Bernoulli:

Realização de uma experiência e registre se houve sucesso, ou se não houve

Probabilidade de K sucessos e M erros independentes?

$$P(\text{sucesso}) = p$$

$$P(\text{erro}) = 1-p$$

• Probabilidade de K sucessos e

M-K erros é

$$\left\{ \begin{array}{l} P^K \cdot (1-p)^{M-K} \\ \frac{M!}{K!(M-K)!} \end{array} \right.$$

• Os K sucessos em M, podem ocorrer de  $C_m^k$  maneiras

$$P_m(k) = C_m^k \cdot P^K \cdot (1-p)^{M-K}$$

$$C_m^k = \binom{M}{K} = \frac{M!}{K!(M-K)!} = \binom{M}{m-K}$$

Ponto de vista frequentista:

$$P(A|B) \approx \frac{k_{A \in B}/N}{k_B/N} = \frac{k_{A \in B}}{k_B} \rightarrow \text{número de ocorrência de "A e B"} / \text{ocorrência de B}$$

frequência (AB)

frequência (A)

frequência (B)

Axiomas:

• Logicamente independentes

• Geometria

$$\textcircled{1} \quad P(A) \geq 0$$

$$\textcircled{2} \quad P(S) = 1$$

$$\textcircled{3} \quad \text{Se } P(A) \cap P(B) = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$$

Teoremas  $\Rightarrow$  obtidos dos axiomas, por deduções.

Teoremas:

$$\textcircled{1} \quad P(\bar{A}) = 1 - P(A)$$


$$\textcircled{2} \quad P(A \cup B) = P(A) + P(B)$$

$$\textcircled{3} \quad P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Teorema 2:

$$\textcircled{1} \quad P(\bar{A}) = 1 - P(A)$$

$$\textcircled{2} \quad P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad \text{ver de } A \cup B = A\bar{B} \cup A\bar{B} \cup \bar{A}\bar{B}$$



$$\textcircled{3} \quad P(A \cup C | B) = P(A|B) + P(C|B) - P(A \cap C | B)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A \cup C | B) = \frac{P((A \cup C) \cap B)}{P(B)} =$$

$$= \frac{P((A \cap B) \cup (C \cap B))}{P(B)} =$$

$$= P(A \cap B) + P(C \cap B) - P(A \cap B \cap C \cap B)$$

$$= P(A|B) + P(C|B) - P(AC|B)$$

cqd

Axiomáticos, verificando por:


- Lei de Laplace
- Definição frequentista

Probabilidades em espacos de amostragem não contáveis:

• Há experiências em que os resultados possíveis ocorrem no domínio de IR (infinito)

Assim, uma das situações mais simples é considerar intervalos em que qualquer valor é igualmente provável. ex:  $S = [a, b]$

Exemplo:



$A \Rightarrow$  número do  $[a, b]$  pertence a  $[d, c]$

$\boxed{[d, c]}$

$$P(A) = \frac{d-c}{b-a}$$

$$P(\text{algum ponto } x \in [a, b]) = 0!$$


Exemplo:  $A_{\text{alto}} = [0, 90]$

Seja  $A$ , "degrau dentro da tolerância" =  $[0, 15] \cap [0, 90]$

$$P(A) = \frac{15-0}{90-0} = 0.17$$

Variáveis aleatórias:

- funções que mapeiam o espaço amostral no. reta real
- é o resultado numérico das nossas experiências aleatórias



Variação classificada

atômico e sólido

atômico e líquido

A e B são eventos equivalentes

Dividiremos em: se os valores assumidos pelo evento são todos

- ① Discretos: valores finitos, ou infinitos mas contáveis (ex 1, 2, ...)
- ② Contínuos: valores formam intervalos distintos.
- ③ Mistos: Discretos e Contínuos

Função de massa de probabilidade:

$$\bullet P_x(x_i) = P(X=x_i)$$

onde  $P(X=x_i) = P(w: X(w) = x_i)$ , ou seja,

$$\bullet P_x(x_i) \geq 0$$

$$\bullet \sum_i P(x_i) = 1$$

A probabilidade do resultado  $w$  do evento  $X(w)$  satisfazer  $X(w) = x_i$ .


Função de probabilidade:

Domínio de cada equilíbrio é  $X$  igual ao m que sai

Variável aleatória  
discreta.

Função de probabilidade  $\Rightarrow x_i = \{1, 2, 3, 4, 5, 6\}$

$$P_X(x_i) = \frac{1}{6}$$




Função distribuição acumulada (discreta)

$$F_X(x) = P_X(x \leq x) = \sum_{i: x_i \leq x} P_X(x_i)$$

$$\lim_{x \rightarrow -\infty} F_X(x) = 0$$

$$\lim_{x \rightarrow +\infty} F_X(x) = 1$$

Função excede



Variáveis aleatórias contínuas:

Também podem ser especificadas pelo seu função distribuição acumulada:

$$F_X(x) = \text{Prob}(X \leq x)$$

contínuo  
 $\geq 0$   
 $\leq 1$

$$a < b \rightarrow F_X(a) \leq F_X(b)$$

$$P[a < X \leq b] = F_X(b) - F_X(a)$$

Poderem ser especificados pelo função de densidade de probabilidade

$$f_X(x) = \frac{d F_X(x)}{dx}$$

## Função de densidade de probabilidade:

•  $f_X(x)$  é probabilidade



$$\bullet P(a < X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(x) dx$$

•  $\int_x(x) dx$  é a probabilidade de variável  $X \in$  o intervalo  $(x, x+dx)$ , nessa dx é um espaço infinitesimal

$\int_x(x) dx$  é proba  $\frac{dx}{dx} \rightarrow$  densidade

## Relação com a função de distribuição:

$$\bullet F_X(x) = \int_{-\infty}^x f_X(x) dx$$



$$\bullet P(1 \leq x \leq 2) = \text{Área da unha}$$

$$\bullet \text{Área total da curva} = 1$$

## Média:

$$\bullet \sum_i p(x_i) \cdot x_i$$

Para n lançamento de 1 dado

$$P(1)x_1 + P(2)x_2 + \dots + P(6)x_6$$

## Valor esperado:

• O valor esperado de  $X$  é o valor médio de  $X$  se repetirmos os experimentos

$$\Rightarrow = \lim_{M \rightarrow +\infty} \frac{x_1 + x_2 + \dots + x_M}{M}$$

$\alpha$  o limite não existir então  
não há valor esperado.

Só existe se  $x_i$  tiver limite inferior e superior finita (ex: peso  $\geq 0$ )

$x_i$  é um diferente valor que  $X$  pode assumir e  $K_{i,n}$  é a probabilidade que ocorre esse valor  $x_i$ , ou seja,

- $\lim_{n \rightarrow \infty} \frac{x_1 K_{1,n} + x_2 K_{2,n} + \dots + x_n K_{n,n}}{n} = E[X]$

- $\sum_{i=0}^{\infty} x_i p(x=x_i)$

Valor esperado  $\rightarrow$  sugestão, pois na realidade não é algo que devemos esperar que ocorra, sendo que muitas vezes é improvável/impossível.  
(ex: valor esperado de sorteio de 6 jogos é 3,5)

→ denotamos por  $E[X]$

cálculo  $\rightarrow E[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$

direto  $\rightarrow E[X] = \sum_i x_i p(x_i)$

$\hookrightarrow$  operador linear  $\Rightarrow$  •  $E[aX] = aE[X]$

•  $E[X+Y] = E[X] + E[Y]$

•  $E[X+c] = E[X] + c$

Exemplo:

$x_i$	$p_X(x_i)$	$x_i p(x_i)$
-1	0,1	-0,1
0	0,2	0
1	0,4	0,4
2	0,2	0,4
3	0,1	0,3

$E[X] = -0,1 + 0 + 0,4 + 0,3 - 0,7 = 1$

## Variância:

Juntar-nos a dispersão.

Histograma: Usar a dispersão de valores da variável para fazer a sim. média

$$\text{Var}(x) = E[(x - E(x))^2]$$

$$\text{Var}(x) = \sum_i [x_i - E(x)]^2 p(x_i)$$

$$\text{Var}(x) = E[x^2] - E^2[x]$$

Desvio padrão:

$\sigma$  → medida da dispersão da variável

$$\sigma = \sqrt{\text{Var}(x)}$$

Slide 37

Variância - propriedades:

$$\begin{cases} x \in \text{var. aleatória} \\ c \in \text{ns constante} \end{cases}$$

$$E[x+c] = E[x] + c$$

$$\text{Var}(x+c) = \text{Var}(x)$$

$$\text{Var}(cx) = c^2 \text{Var}(x)$$

$E[x]$  → valor médio de  $x$

→ centro da gravidade da função massa de probabilidades / densidade ou da função densidade de probabilidade

Desviopadrão / variância:

→ dão a dispersão da sua variável aleatória

→ Se for 0, então não existe var. aleatória (todos valores = média)

do estudo n.

caso discrete

caso contínuo

Momôtos de orden M:

$$\text{Casô discreto} \rightarrow m_m = E[X^m] = \sum_i x_i^m p_x(x_i)$$

Exemplo dos dados:

$$E[X^2] = 1^2 \times \frac{1}{6} + 2^2 \times \frac{1}{6} + \dots + 6^2 \times \frac{1}{6} = 15,17$$

Momôtos estrutados de orden M:

- Resulta na generalização da variância

$$E[(X - E[X])^m] = \sum_i (x_i - E[X])^m p(x_i)$$

- Variância  $\rightarrow$  momôto estrutado de 2º orden

## Distribuições Discretas

- Funções massa e densidade de probabilidade podem assumir fôrmas:

Distribuições:

① Discretas:

- Bernoulli
- Binomial
- Poisson

② Contínuas:

- Uniforme
- Normal

## Distribuições Discretas:

Variável do Bernoulli

(I\_A)

$$I_A(w) = \begin{cases} 1, & \text{se } w \in A \\ 0, & \text{se } w \notin A \end{cases}$$


↓ indicadora de ocorrência

Exemplo:

- $S_I = \{0, 1\}$
- $p = P_A(A)$

$$\rightarrow P_I(1) = p$$

$$P_I(0) = 1-p$$



Valor esperado:

$$\cdot E[I] = \sum_i x_i p(x_i) = 0 \times (1-p) + 1 \times p = p$$

Variância:

$$\begin{aligned} \text{Var}(I) &= E[I^2] - (E[I])^2 = 0^2 \cdot (1-p) + 1^2 \cdot p - (p)^2 \\ &= p - p^2 = p(1-p) \end{aligned}$$

## Variável Binomial

$$\cdot \frac{x}{\downarrow} = \sum_{j=1}^m I_j \rightarrow S_x = \{0, 1, 2, \dots, m\}$$

número de sucessos em  
m experiências

$$\cdot P_X(k) = P_n(X=k) = \binom{m}{k} p^k (1-p)^{m-k}$$

$$\cdot f_X(x) = \sum_{k=0}^x \binom{m}{k} p^k (1-p)^{m-k}$$

Média:

$$E[x] = E[\sum x_i] = \sum E[x_i] = mp$$

Variância

$$\text{Var}(\sum x_i) = \sum \text{Var}(x_i) = mp(1-p)$$

Exemplos:

- Nº de pesos defeituosos em lote de 50 pesos

$$q = \left(\frac{1}{2}\right) \cdot \frac{1}{2} = \frac{1}{4}$$

$$\lambda_{\text{min}} - \lambda_{\text{max}} = (1-p)/p^2$$

$$\overline{M_{\text{ridic}}} \leftarrow E[x] = \frac{1}{P}$$

$$1-x^{\frac{p}{d-1}} = (x^{\frac{1}{d-1}})^{p-1}$$

$$P_x(k) = p(1-p)$$

$$d = (\text{arrow}) d$$

over and over again

$X \leftarrow \text{max}(\text{values})$  que é o menor número dentro da lista - aquela é a sua definição de *minimum*.

downward growth

$$P(X \leq x) = 0,8901 + 0,3703 + 0,2246 = 0,8850$$

$$f(x=0) = \frac{(0.06)^0 + (0.94)^0}{2^0} = \frac{1 + 1}{1} = 2$$

$$P(X \leq 2) = P(X=0) + P(X=1) + P(X=2)$$

$$nb = 0.9$$

$$P(\text{decodes}) = 0.9$$

cosmopolitan

He goes on in his words to tell of his 'old man', such a good old fellow as he.

caption strap

As regards the costs, ex. des indemnifications de l'assurance sociale

Exemplo:

- $p(\text{sucesso}) = 0,1$
- $p(\text{necessitar mais de 3 chaves para successo}) = ?$

$$P(\leq 3) = p(1) + p(2) = p(1-p)^{1-1} + p(1-p)^{2-1} = p + p(1-p) = \\ = p + p - p^2 = 2p - p^2 = 0,2 - 0,01 = 0,19$$

### Distribuição de Poisson

- Surgiu devido à generalização da função binomial para valores de n elevados.

Consideramos que existe um variável Binomial, mas,  $p_{\text{decrece}} \approx mp \rightarrow \lambda > 0$   
Podemos aproximar, para n grande:

$$p \approx \frac{\lambda}{n} \quad 1-p \approx 1-\frac{\lambda}{n}$$

$$P_x(k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

→ Função de massa de probabilidade da distribuição de Poisson, com  $k=0, 1, 2, \dots$

Distribuição para os vários valores de  $\lambda$ :

Função probabilística  $\rightarrow P_x(k) = P_r(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}$

Média  $\Rightarrow E[X] = \lambda$

Variância  $\Rightarrow V(X) = \lambda$

### Variável de Poisson

- Jogo-se no m de ocorrências (discreto), num intervalo, ou contínuo
- Esta distribuição não tem m de experiências (m)

Slide 30

$$\lambda = \mu$$

Distribuição de Poisson  $\rightarrow$  usado quando n.º grande e p.º pequeno (eventos raros), subindo a distribuição binomial

Regras: Se  $n > 20$  e  $mp \leq 7 \Rightarrow$  usa-se a aproximação de Poisson!

Quais são as aproximações da distribuição binomial por Poisson?

① Calcular média binomial:  $\mu = mp$

②  $\lambda = E(x) = \mu$

③ Usar:  $p_x(k) = \frac{\lambda^k}{k!} e^{-\lambda}$

Exemplo:

Chegam 3,2 diétas em 4 minutos, em média.

Probabilidade de chegarem mais de 7 diétas em 4 minutos?

$$P(X > 7 \text{ diétas/4 minutos}) = ?$$

$$\lambda = ?$$

$$\lambda = 3,2 \text{ [dietas em 4 minutos]}$$


$$P(X > 7) = 1 - \sum_{k=0}^{7} \frac{0,32^k \cdot e^{-0,32}}{k!} = 0,0169$$

## Distribuições Contínuas

Variável aleatória uniforme:

$$f_x(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases}$$

$$F_x(x) = \begin{cases} 0, & x < a \\ \frac{1}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$$



$$E[X] = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

Exemplo:

$$P(45 \leq X \leq 47) \text{, com } U(41, 47)$$

$$P(x_1 \leq X \leq x_2) = \frac{x_2 - x_1}{b-a} = \frac{47 - 45}{47 - 41} = \frac{2}{6} = \frac{1}{3}$$

Variável aleatória Normal/ Gaussiana:

$$\text{Se: } f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\text{Notação: } \mathcal{N}(\mu, \sigma^2)$$

$\mu$  = média  
 $\sigma$  = desvio



$$\bullet E[X] = \mu$$

$$\bullet \text{Var}[X] = \sigma^2$$

• Nota: se variáveis 2 possuem  $\rightarrow$

Gaussiana Normalizadas

- Núcleo infinito de combinações de  $\mu$  e  $\sigma^2 \rightarrow$  Possível infinito de curvas
- Mas é necessário que permita obter uma distribuição única (equacionar  $N(0,1)$ ) que converge quando normalizar só  $\mu$



modo: subtrair a média e dividir pelo desvio padrão

$$Z = \frac{X - \mu}{\sigma}$$

Função densidade de probabilidade  $\Rightarrow \phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\left(\frac{(x-\mu)^2}{2}\right)}$

Função distribuição acumulada  $\rightarrow$

→ pode, também, ser expressa:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2}} dt$$

$$F_x(x) = \Phi\left(\frac{x-\mu}{\sigma}\right) \quad Q(x) = 1 - \Phi(x)$$

Exemplo: Vamos expressar em termos da variável normal  
uma variável normal  $X$ , que segue

uma distribuição normal

$$N(75, 10^2). \quad P(78 < X < 80) = ?$$

$$\begin{aligned} \mu &= 75 \\ \sigma &= 10 \end{aligned}$$

$$P[78 < X < 80] = P\left[\frac{78-75}{10} \leq \frac{X-\mu}{\sigma} \leq \frac{80-75}{10}\right] =$$

$$= P(0,3 \leq U_x \leq 0,5) = Q(0,3) - Q(0,5) = 0,074$$

Distribuição Binomial é a variação

$$\begin{aligned} m &= np \\ \sigma &= \sqrt{n \cdot p(1-p)}, \text{ com } m \text{ muito} \end{aligned}$$

muito pequeno e  $n$  elevado.

aproximando por:

$$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(k-m)^2}{2\sigma^2}}$$

Distribuição normal, desde que  $m = np$  e  
variação  $= np(1-p)$

## Distribuição exponencial:

$$f_X(x) = \begin{cases} 0, & \text{se } x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$$



$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$



slis 1%

$$\mathbb{E}[X] = \frac{1}{\lambda}$$

$$\text{Ans.} \rightarrow \text{Probabilidade}$$

### Exemplo:

A vida útil de um robô é uma variável aleatória com distribuição exponencial de valor médio 10 horas.

Qual a probabilidade de um robô, selecionado ao acaso, ter vida inferior a 4 horas?

$$\lambda = \frac{1}{10} = 0,1$$

$$P[X < 4] = (1 - e^{-0,1 \cdot 4}) = 0,33$$

$$P[X < 4] = \int_0^4 0,1 e^{-0,1 x} dx$$

## Distribuição normal vs distribuição exponencial

• características físicas  
(altura, peso, ...)

• problemas de filas de espera e fiabilidade

(ex: tempo útil em PC avançado)

• surge quando vários efeitos  
combinados e independentes se  
sobrepõem

• relacionada com a distribuição (discreta) de

Poisson

## Leis de distribuição:

~~$$\boxed{\text{Lei de Benford}} \rightarrow P(d) = \log_{10} \left( 1 + \frac{1}{d} \right)$$~~

⇒ dígitos primos digitos

⇒ opção surpreendente de fuentes, erros de digitação, etc

~~$$\boxed{\text{Lei do Zipf}} \rightarrow p(n) = \frac{K}{n} \rightarrow \text{constante dependente da língua}$$~~

prevê que a ocorrência de uma palavra, num texto, está ligada à sua ordem.

- Utilizam-se áreas de segurança

### Variáveis aleatórias - multidimensionais:

ex: Relação altura peso

- 2 tipos de casos:
  - ① Experiência aleatória com vários saídas
  - ② Repetição de experiência aleatória com apenas 1 saída

Vetor aleatório →  $\underline{x} = (x_1 \ x_2 \ \dots \ x_n)$

Exemplo:  $x = (H \ W \ A)$

Variáveis aleatórias

$H(\xi) =$  altura de  $\xi$

$W(\xi) =$  peso de  $\xi$

$A(\xi) =$  idade de  $\xi$

## Funções de distribuição conjuntas:


obtem-se através da extensão das definições para 2 variáveis

### Função probabilística de prob. conjunta

para variáveis discritas  $X$  e  $Y$ :

$$P_{X,Y}(i,j) = P(X=i \wedge Y=j)$$

representação 3D



$\rightarrow X \rightarrow$  dado 1  
 $\rightarrow Y \rightarrow$  dado 2

$$P_{X,Y}(1,1) = P_{X,Y}(1,2) = \dots = P_{X,Y}(1,6)$$
$$= \frac{1}{6} \times \frac{1}{6} = \frac{1}{36}$$

### Função de distribuição acumulativa conjunta

$$F_{X,Y}(x,y) = P(X \leq x \wedge Y \leq y)$$

Distribuição de cada uma das variáveis:

$$F_X(a) = P(X \leq a) = P(X \leq a, Y < \infty) = F_{X,Y}(a, \infty)$$

função de massa de probabilidade da cotação das variáveis:

$$P_X(x) = \sum_y P_{X,Y}(x,y)$$

$$P_Y(y) = \sum_x P_{X,Y}(x,y)$$

com - se os lados apropriados da

tabela

		$B(y_2)$		$P(y_1)$
$A(y_1)$		0	1	
	0	0,3	0,4	0,7
$P(y_2)$	1	0,2	0,1	0,3
	1	0,5	0,5	1

Propriedade:  $P_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1=x_1, \dots, X_n=x_n)$

→ Caso de  $n$  variáveis discrete

Função Massa de probabilidade conjunta

$$P_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1=x_1, \dots, X_n=x_n)$$

Função de probabilidade marginal para  $X_1$

$$P_{X_1}(x_1) = \sum_{x_2, \dots, x_n} P_{X_1, \dots, X_n}(x_1, \dots, x_n)$$

Função de probabilidade marginal para  $X_1$  e  $X_2$

$$P_{X_1, X_2}(x_1, x_2) = \sum_{x_3, \dots, x_n} P_{X_1, \dots, X_n}(x_1, x_2, \dots, x_n)$$

Independência:

$X$  e  $Y$  são independentes se, para qd qd  $a$  e  $b$ :

$$\cdot P(X \leq a, Y \leq b) = P(X \leq a) P(Y \leq b), \text{ ou seja}$$

$$\cdot E_a = \{X \leq a\} \text{ e } E_b = \{Y \leq b\} \text{ são independentes}$$

Caso disjunta:

$$p(x, y) = p_X(x) \times p_Y(y)$$

Caso contínuo:

$$f_{XY}(x, y) = f_X(x) \cdot f_Y(y)$$

Momentos céticos

Momentos céticos conjuntos de orden  $j, k$  das variáveis  $X, Y$ :

$$E[X^j Y^k] = [(X - E[X])^j (Y - E[Y])^k]$$

$j$	$k$	
2	0	Variancia
0	2	
0	1	valores reais de $X, Y$
1	0	
1	1	Coelocação

Quando  $j = k = 1 \Rightarrow E[X \cdot Y]$  é a covariância das variáveis  $X e Y$ .

Se  $E[X \cdot Y] = 0 \Rightarrow$  variáveis ortogonais

Se  $X e Y$  independentes:

$$E[X \cdot Y] = E[X] \cdot E[Y]$$

Covariância de  $X, Y$

Quando  $j = k = 1$

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

$$\text{Var}(X) = \text{Cov}(X, X)$$

Relação não linear  $\rightarrow$  covariância pode não ser reversível à relação

Se  $\text{Cov}(X, Y) = 0 \Rightarrow X e Y$  independentes


Propriedades da covariância

- $\text{Cov}(X, X) = \text{Var}(X)$
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- $\text{Cov}(cX, Y) = c \text{Cov}(X, Y)$
- $\text{Cov}(X, Y+Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$

Se tivermos  $Y = (Y_1, Y_2, \dots, Y_m) \rightarrow$  vetor de v.a.

$$(Y) = \begin{bmatrix} \text{Cov}(Y_1, Y_1) & \cdots & \text{Cov}(Y_1, Y_m) \\ \vdots & \ddots & \vdots \\ \text{Cov}(Y_m, Y_1) & \cdots & \text{Cov}(Y_m, Y_m) \end{bmatrix} = \begin{bmatrix} \text{Var}(Y_1) & \cdots & \text{Cov}(Y, Y_1) \\ \vdots & \ddots & \vdots \\ \text{Cov}(Y_1, Y_m) & \cdots & \text{Var}(Y_m) \end{bmatrix}$$

ha um troco



$$E[X] = 1(0,1+0,2) + 3(0,2+0,2+0,3) = 2,4$$

$$E[Y] = 1(0,3) + 2 \cdot 0,4 \cdot 3 \times 0,3 = 2,1$$

$$\begin{aligned} \text{Cov}(X,Y) &= E[(X-E[X])(Y-E[Y])] = \\ &= (1-2,4)(1-2,1) \cdot 0,1 + (1-2,4)(2-2,1) \cdot 0,2 + \\ &+ (3-2,4)(1-2,1) \cdot 0,2 + (3-2,4)(2-2,1) \cdot 0,2 + \\ &+ (3-2,4)(3-2,1) \cdot 0,3 = 0,2 \end{aligned}$$


coeficiente de correlação de  $X$  e  $Y$ :

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \cdot \sigma_Y} \quad -1 \leq \rho_{X,Y} \leq 1$$

$\rightarrow$  Se  $\rho_{X,Y} = 0 \rightarrow$  variáveis descorrelacionadas

$\bullet$   $X$  e  $Y$  independentes  $\rightarrow \text{Cov}(X,Y) = 0$ ,  $\rightarrow$  o contrário não é verdadeiro

Exemplo



x	y	$P(x,y)$	$xyP(x,y)$	$xP(x)$	$yP(y)$	$x^2P(x)$	$y^2P(y)$
0	0	0,2	0	0	0	0	0
1	1	0,1	0,1	0,1	0,1	0,1	0,1
1	2	0,1	0,2	0,1	0,2	0,1	0,4
2	1	0,1	0,2	0,2	0,1	0,4	0,1
2	2	0,1	0,4	0,2	0,2	0,4	0,4
3	3	0,4	3,6	1,2	1,2	3,6	3,6
SUM		1	4,5	1,8	1,8	4,6	4,5

$$\text{Var}(x) = E[x^2] - (E[x])^2 = 4,6 - 3,24 = 1,36$$

$$\text{Var}(y) = 1,36$$

$$\text{Cov}(X,Y) = E[XY] - E[X] \cdot E[Y] = 4,5 - (1,8)(1,8) = 1,26 \quad \left| \rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \cdot \sigma_Y} = \frac{1,26}{(\sqrt{1,36})^2} = 0,926 \right.$$